


# VIO 第四章作业

曾卓

May 2021

## 1 第一题

某时刻，SLAM 系统中相机和路标点的观测关系如下图所示，其中  $\xi$  表示相机姿态， $L$  表示观测到的路标点。当路标点  $L$  表示在世界坐标系下时，第  $k$  个路标被第  $i$  时刻的相机观测到，重投影误差为  $r(\xi_i, L_k)$ 。另外，相邻相机之间存在运动约束，如 IMU 或者轮速计等约束。



- 1 请绘制上述系统的信息矩阵  $\Lambda$ .
- 2 请绘制相机  $\xi_1$  被 marg 以后的信息矩阵  $\Lambda'$ .

$$\begin{array}{c}
 \begin{array}{c|c|c|c|c|c|c}
 & \xi_1 & \xi_2 & \xi_3 & L_1 & L_2 & L_3 \\
 \hline
 \xi_1 & \Lambda_{\beta\beta} & & & \Lambda_{\beta\alpha} & & \\
 \xi_2 & & & & & & \\
 \xi_3 & & & & & & \\
 L_1 & \Lambda_{\alpha\beta} & & & \Lambda_{\alpha\alpha} & & \\
 L_2 & & & & & & \\
 L_3 & & & & & & 
 \end{array}
 & \Lambda_{\alpha\alpha} & - & \Lambda_{\alpha\beta} * \Lambda_{\beta\beta}^{-1} * \Lambda_{\beta\alpha} & \\
 & \begin{array}{c|c|c|c|c|c|c}
 & \xi_1 & \xi_2 & \xi_3 & L_1 & L_2 & L_3 \\
 \hline
 \xi_1 & & & & & & \\
 \xi_2 & & & & & & \\
 \xi_3 & & & & & & \\
 L_1 & & & & \Lambda_{\alpha\alpha} & & \\
 L_2 & & & & & & \\
 L_3 & & & & & & 
 \end{array}
 & - & \begin{array}{c} \xi_2 \\ \xi_3 \\ L_1 \\ L_2 \\ L_3 \end{array} \times \begin{array}{c} \xi_1 \end{array} \times \begin{array}{c|c|c|c|c|c|c}
 & \xi_2 & \xi_3 & L_1 & L_2 & L_3 \\
 \hline
 \xi_2 & & & & & & \\
 \xi_3 & & & & & & \\
 L_1 & & & & & & \\
 L_2 & & & & & & \\
 L_3 & & & & & & 
 \end{array}
 & = & \begin{array}{c|c|c|c|c|c|c}
 & \xi_2 & \xi_3 & L_1 & L_2 & L_3 \\
 \hline
 \xi_2 & & & & & & \\
 \xi_3 & & & & & & \\
 L_1 & & & & & & \\
 L_2 & & & & & & \\
 L_3 & & & & & & 
 \end{array}
 \end{array}$$

## 2 第二题

阅读《Relationship between the Hessian and Covariance Matrix for Gaussian Random Variables》. 证明信息矩阵和协方差的逆之间的关系。

### 2.1 问题定义

对于参数为  $\theta$  的概率分布  $p(x|\theta)$ , 此处  $x$  已知,  $\theta$  为待估计变量, 分别定义了以下三个矩阵:

1. **信息矩阵 Fisher Information Matrix** 定义为  $F := \mathbb{E}_{p(x|\theta)}[(s(\theta) - 0)(s(\theta) - 0)^\top]$ ,

其中  $s(\theta)$  为 score function, 即 log likelihood 函数的导数  $s(\theta) := \nabla_\theta \log p(x|\theta)$  易证其期望为 0。Fisher Information 可以理解为用来最大似然估计的方程 (即 score function) 的方差, 也可以理解为 log likelihood 函数在参数真实值处负的二阶导数 (Hessian) 的期望 (证明见 2.3)

2. **Hessian 矩阵** 实际上经常指的是 log likelihood 函数的二阶导函数

3. **协方差矩阵 Covariance Matrix**  $\Sigma = \text{cov}(X, X) = E[(X - E(X)) \cdot (X - E(X))^\top]$

### 2.2 先证明协方差矩阵和 Hessian 的关系

对于均值为  $\mu$ , 协方差矩阵为  $\Sigma_\theta$  的高斯分布

$$p(\theta) = (2\pi)^{-\frac{N_\theta}{2}} |\Sigma_\theta|^{-\frac{1}{2}} \exp \left[ -\frac{1}{2} (\theta - \mu)^T \Sigma_\theta^{-1} (\theta - \mu) \right] \quad (1)$$

取负对数后

$$J(\theta) \equiv -\ln p(\theta) = \frac{N_\theta}{2} \ln 2\pi + \frac{1}{2} \ln |\Sigma_\theta| + \frac{1}{2} (\theta - \mu)^T \Sigma_\theta^{-1} (\theta - \mu) \quad (2)$$

求二阶导后易得 log likelihood 函数的  $Hessian = \Sigma_\theta^{-1}$  即对于高斯分布 Hessian 为协方差矩阵的逆, 对于其它分布协方差的逆也可以提供较好的估计 (不是高斯分布时, 为  $\approx$ , 若采用 finite difference 的数值方法时还取决于步长和选取来求 Hessian 的点)。

### 2.3 再证明 Hessian 和信息矩阵的关系

参考<https://wiseodd.github.io/.../fisher-information>

Hessian 为二阶导即对一阶梯度的导数

$$\begin{aligned} H_{\log p(x|\theta)} &= J \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right) \\ &= \frac{H_{p(x|\theta)} p(x|\theta) - \nabla p(x|\theta) \nabla p(x|\theta)^\top}{p(x|\theta) p(x|\theta)} \\ &= \frac{H_{p(x|\theta)} p(x|\theta)}{p(x|\theta) p(x|\theta)} - \frac{\nabla p(x|\theta) \nabla p(x|\theta)^\top}{p(x|\theta) p(x|\theta)} \\ &= \frac{H_{p(x|\theta)}}{p(x|\theta)} - \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right) \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right)^\top \end{aligned} \quad (3)$$

$$\begin{aligned}
\mathbb{E}_{p(x|\theta)} [\mathbf{H}_{\log p(x|\theta)}] &= \mathbb{E}_{p(x|\theta)} \left[ \frac{\mathbf{H}_{p(x|\theta)}}{p(x|\theta)} - \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right) \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right)^T \right] \\
&= \mathbb{E}_{p(x|\theta)} \left[ \frac{\mathbf{H}_{p(x|\theta)}}{p(x|\theta)} \right] - \mathbb{E}_{p(x|\theta)} \left[ \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right) \left( \frac{\nabla p(x|\theta)}{p(x|\theta)} \right)^T \right] \\
&= \int \frac{\mathbf{H}_{p(x|\theta)}}{p(x|\theta)} p(x|\theta) dx - \mathbb{E}_{p(x|\theta)} [\nabla \log p(x|\theta) \nabla \log p(x|\theta)^T] \\
&= \mathbf{H}_{\int p(x|\theta) dx} - \mathbf{F} \\
&= \mathbf{H}_1 - \mathbf{F} \\
&= -\mathbf{F}
\end{aligned} \tag{4}$$

对于取负对数的时候  $F = E_{p(x|\theta)}[\mathbf{H}_{\log p(x|\theta)}] \approx E_{p(x|\theta)}[\Sigma_\theta^{-1}]$

由于  $\Sigma_\theta^{-1}$  项为  $\theta$  分布的真实协方差矩阵的逆，与  $x$  无关，故可将期望去掉得到  $F \approx \Sigma_\theta^{-1}$

另外对于高斯牛顿法中  $\mathbf{H}$  矩阵通常是由  $\mathbf{H} = \mathbf{J}^T \Sigma^{-1} \mathbf{J} = \sum_{i=1}^n \mathbf{J}_i^T \Sigma_i^{-1} \mathbf{J}_i$  近似得到的，此处  $\Sigma$  为残差项的协方差，与我们上面证明中出现的协方差  $\Sigma_\theta$  不一样。

所以最后的结论是：协方差矩阵的逆  $\approx$  Hessian 矩阵，信息矩阵 = Hessian 的期望  $\approx$  协方差的逆。

### 3 第三题

请补充作业代码中单目 Bundle Adjustment 信息矩阵的计算，并输出正确的结果。正确的结果为：奇异值最后 7 维接近于 0，表明零空间的维度为 7，即单目 SLAM 下系统有 7 自由度不可观。

```

H.block(i*6,i*6,6,6) += jacobian_Ti.transpose() * jacobian_Ti;
/// 请补充完整作业信息矩阵块的计算
// H.block(?,?,?,?) += ?; /* 3 blocks
// H = | pp pl |
//      | lp ll |
// compute block lp
H.block(6*poseNums + 3*j, 6*i, 3, 6) += jacobian_Pj.transpose() * jacobian_Ti;
// compute block pl
H.block(6*i, 6*poseNums + 3*j, 6, 3) += jacobian_Ti.transpose() * jacobian_Pj;
// compute block ll
H.block(6*poseNums + 3*j, 6*poseNums + 3*j, 3, 3) += jacobian_Pj.transpose() * jacobian_Pj;

```

图 1: 信息矩阵计算代码

```

3.21708e-17
2.06732e-17
1.43188e-17
7.66992e-18
6.08423e-18
6.05715e-18
3.94363e-18

```

图 2: 奇异值分解后，最小的 7 个奇异值